

Aplicarea Rețelelor Neuronale Convoluționale pentru Diagnosticarea Automatizată a Cancerului de Piele

Balint Cătălin-Vasile

Abstract

Această documentație detaliază dezvoltarea unui sistem de clasificare automată a tipurilor de cancer de piele, implementat prin utilizarea tehnologiilor de învățare profundă oferite de TensorFlow și Keras. Proiectul se concentrează pe construirea și antrenarea de rețele neuronale convoluționale (CNN) pentru a distinge între nouă tipuri diferite de leziuni cutanate, utilizând un set extensiv de date imagistice prelucrate și augmentate pentru a îmbunătăți acuratețea modelului. Utilizăm modele pre-antrenate, cum ar fi ResNet50 și VGG19, adaptate pentru sarcina specifică prin fine-tuning, și explorăm efectul augmentării datelor asupra performanței de clasificare.

Scopul final al proiectului este de a furniza un instrument de diagnosticare asistată, care să ajute medicii în evaluarea rapidă și precisă a potențialelor cazuri de cancer de piele, contribuind astfel la îmbunătățirea rezultatelor clinice prin detectarea timpurie și intervenția promptă. Evaluarea modelului pe seturi de date de test demonstrează capacitatea sistemului de a clasifica cu acuratețe tipurile de cancer de piele, deschizând calea către aplicații practice în domeniul medical.

1 Introduction

În contextul actual, în care incidența cancerului de piele continuă să crească la nivel global, dezvoltarea de soluții tehnologice avansate pentru detectarea timpurie a diferitelor tipuri de cancer de piele devine imperativă. Tehnologia de învățare automată, și în special învățarea profundă (deep learning), oferă un-

elte promițătoare pentru asistarea dermatologilor în diagnosticarea precisă și rapidă a leziunilor cutanate maligne și benigne. Utilizarea rețelelor neuronale convoluționale (CNN), o clasă de învățare profundă, s-a dovedit a fi deosebit de eficace în interpretarea imaginilor medicale, datorită capacității lor de a extrage caracteristici complexe și de a învăța ierarhii de trăsături direct din datele brute.

Proiectul meu își propune să exploateze această capacitate, aplicând tehnicile de învățare automată pentru a clasifica imagini dermatoscopice în nouă categorii diferite de cancer de piele. Sistemul nostru utilizează o combinație de modele CNN pre-antrenate și tehnicile de augmentare a datelor pentru a îmbunătăți acuratețea diagnosticării. Scopul este de a oferi o soluție scalabilă și eficientă care să poată fi integrată în fluxurile de lucru clinice, reducând astfel povara diagnosticării manuale și sporind șansele de tratament reușit prin detectarea precoce.

Documentația prezentată explică detaliat procesele de configurare a mediului de dezvoltare, preprocesarea datelor, construcția și antrenarea modelelor, precum și evaluarea performanței acestora. Prin integrarea învățării automate în diagnosticarea cancerului de piele, proiectul nostru contribuie la avansarea tehnologiilor de sănătate și deschide noi perspective pentru aplicabilitatea inteligenței artificiale în medicină.

2 Set de Date

Setul de date utilizat în acest proiect provine de la The International Skin Imaging Collaboration (ISIC)

și constă în 2357 de imagini, împărțite în categorii ce reprezintă diferite boli oncologice maligne și benigne. Aceste imagini sunt structurate în două directoare principale: Train și Test, fiecare conținând subdirectoare pentru fiecare tip de boală diagnosticată.

Setul de date include următoarele categorii de boli:

- Actinic Keratosis
- Basal Cell Carcinoma
- Dermatofibroma
- Melanoma
- Nevus
- Pigmented Benign Keratosis
- Seborrheic Keratosis
- Squamous Cell Carcinoma
- Vascular Lesion

Distribuția acestor categorii este echilibrată, cu excepția melanomelor și alunițelor (nevus), unde numărul de imagini este ușor predominant. Această structurare ajută la crearea unui model de învățare automată care poate identifica și diferenția eficient între mai multe tipuri de leziuni cutanate, cu o atenție sporită acordată celor mai frecvent întâlnite în practica clinică.

Setul de Antrenament (Train): Include majoritatea datelor și este utilizat pentru a construi și antrena modelul. Fiecare categorie de boală are un subdirector corespunzător, facilitând procesul de antrenare supervizată a modelului.

Setul de Test (Test): Folosit pentru a evalua capacitatea modelului de a generaliza și de a clasifica corect noile exemple, pe baza datelor care nu au fost prezentate modelului în timpul antrenamentului.

Imaginile sunt preprocesate înainte de a fi folosite în antrenament, incluzând redimensionarea la dimensiuni uniforme (224x224 pixeli) și normalizarea valorilor pixelilor. Augmentarea datelor este realizată pentru a îmbunătăți robustețea modelului, utilizând tehnici precum rotirea, zoom-ul și ajustările de poziție, pentru a simula diferite condiții în care pot fi capturate imagini în practica reală.

Această structurare riguroasă a setului de date asigură că modelul de învățare automată dezvoltat este bine antrenat și capabil să performeze cu acuratețe în condiții variate, un aspect crucial în aplicarea practică în domeniul diagnosticării medicale.




Figure 1: Leziune vasculara

3 Related Work

În cadrul lucrării de față, am consultat multiple resurse pentru a ne informa despre cele mai recente metode și tehnici în clasificarea imaginilor și înțelegerea bolilor de piele. Resursele includ articole științifice, tutoriale și seturi de date public disponibile, care au fost esențiale în dezvoltarea și evaluarea metodologiilor noastre.

3.1 Resurse și Linkuri

Următoarele linkuri au fost consultate în cursul cercetării:

Manipularea imaginilor folosind OpenCV disponibilă pe Kaggle:

<https://www.kaggle.com/code/pritomsh/manipulating-images-using-opencv>

Informații despre setul de date utilizat pentru clasificarea cancerului de piele:

<https://www.kaggle.com/datasets/nodoubttome/skin-cancer9-classesisic/data>

Ghid pas cu pas pentru clasificarea imaginilor folosind rețele neuronale convoluționale (CNN):

<https://www.analyticsvidhya.com/blog/2021/01/image-classification-using-convolutional-neural-networks-a-step-by-step-guide>

De asemenea, linkurile și resursele găsite pe platformele educaționale Teams și Moodle au fost folosite, în special cele legate de tehnici și aplicații ale CNN în clasificarea automată a imaginilor.

4 Modele

Secțiunea următoare descrie două modele de clasificare a imaginilor utilizate pentru a identifica diferite tipuri de cancer de piele folosind tehnici de învățare profundă. Fiecare model este descris în detaliu în termeni de arhitectură, configurație și performanță.

4.1 Model - Arhitectura Personalizată CNN

Modelul acesta este o rețea neuronală convoluțională (CNN) construită personalizat pentru clasificarea imaginilor de cancer de piele în mai multe categorii, bazate pe caracteristicile vizuale. Arhitectura Modelului acesta cuprinde mai multe straturi concepute pentru a extrage progresiv caracteristici mai complexe din imaginile de intrare,

care sunt preprocesate la o dimensiune standard potrivită pentru stratul de intrare al modelului.

Modelul începe cu un strat convoluțional de 32 de filtre de dimensiunea 3x3, urmat de un strat de max pooling de 2x2, care servește la reducerea dimensiunilor spațiale ale ieșirii și la prevenirea supraadaptării prin furnizarea unei forme abstracte a caracteristicilor de intrare. Acesta este urmat de încă două seturi de straturi convoluționale și de max pooling, numărul filtrelor dublându-se de fiecare dată – 64 și apoi 128. Aceste straturi sunt proiectate pentru a capta caracteristici de nivel superior în imaginile precum marginile, texturile și formele.

După straturile convoluționale, modelul aplatizează ieșirea și o alimentează într-un strat dens de 512 de neuroni, oferind capacitatea de a învăța combinații neliniare ale caracteristicilor de nivel înalt extrase de straturile convoluționale. Urmează un strat de dropout, cu o rată de 0.5, pentru a reduce supraadaptarea prin ignorarea aleatorie a unui subset de caracteristici în timpul antrenamentului.

Ultimul strat al modelului este un strat dens cu funcție de activare softmax. Numărul de neuroni din acest strat corespunde numărului de clase din setul de date, care sunt diferite tipuri de leziuni ale pielii identificate în datele de antrenament. Acest strat oferă o distribuție de probabilitate peste clase, clasificând efectiv imaginea de intrare.

Modelul acesta a fost compilat cu optimizatorul Adam, o alegere populară pentru CNN-uri, care utilizează o rată de învățare adaptivă pentru a ajuta la convergența mai rapidă spre greutățile optime. Modelul utilizează entropia încrucișată categorială ca funcție de pierdere, adecvată pentru sarcinile de clasificare multi-clasă unde fiecare ieșire poate aparține unei singure etichete.

În timpul antrenamentului, Modelul acesta a fost rulat pentru 5 epoci cu loturi de imagini furnizate de un generator de date care efectuează augmentare

de date în timp real. Această augmentare include transformări aleatorii ale imaginilor de antrenament, cum ar fi rotațiile și translațiile, care ajută la îmbunătățirea robusteții modelului prin simularea unei varietăți de condiții de imagistică. Procesul de antrenament a avut ca scop minimizarea pierderii pe un set de validare în timp ce urmărea metrica de acuratețe, care măsoară proporția de etichete prezise corect.

Evaluarea performanței pe setul de test a arătat o acuratețe la test de 30.00 din 100, conform jurnalului de antrenament de la ultima epocă. Acest rezultat subliniază unele provocări cu care se confruntă modelul, posibil din cauza complexității sarcinii și a variabilității imaginilor de cancer de piele.

4.2 Model- Transfer Learning cu ResNet50

Modelul acesta este o implementare a arhitecturii ResNet50 pre-antrenate, adaptată pentru clasificarea binară a imaginilor de cancer de piele. Acest model utilizează tehnici de transfer learning pentru a beneficia de rețeaua neurală profundă dezvoltată și optimizată pe setul de date ImageNet, ceea ce permite o convergență mai rapidă și o performanță îmbunătățită, chiar și cu un număr relativ mic de imagini de antrenament specifice domeniului.

Modelul începe cu baza ResNet50, de la care a fost eliminat stratul superior de clasificare. Acest lucru permite adăugarea unor straturi personalizate pentru a se potrivi nevoilor specifice ale problemelor noastre de clasificare. Următoarele straturi adăugate includ un strat de GlobalAveragePooling2D, care reduce dimensiunea caracteristicilor extrase la o singură dimensiune vectorială, facilitând o tranziție netedă către straturile dense.

Un strat dens de 1024 de unități cu activare 'relu' este folosit pentru a introduce capacitatea de a învăța reprezentări non-liniare ale datelor. Stratul final este un strat dens cu o singură unitate și funcție de activare sigmoidală, proiectat pentru a produce o proba-

bilitate, indicând apartenența fiecărei imagini la clasa pozitivă, în cazul nostru, prezența cancerului de piele.

Modelul a fost compilat folosind optimizatorul Adam și pierderea binary crossentropy, adecvată pentru problemele de clasificare binară. Antrenamentul a fost efectuat pe un set de date care a fost augmentat în timp real folosind ImageDataGenerator. Aceasta a inclus ajustări ale imaginilor prin rotire, translație, flipare orizontală, zoom și ajustare a luminozității pentru a îmbunătăți capacitatea modelului de a generaliza peste variațiile naturale întâlnite în datele clinice.

Modelul a fost antrenat pentru 5 epoci, demonstrând o îmbunătățire constantă în acuratețe și o scădere a pierderii de la o epocă la alta, cu o acuratețe finală de aproximativ 89 din 100 pe setul de antrenament. Aceste rezultate subliniază eficacitatea modelului în clasificarea imaginilor de cancer de piele, beneficiind de arhitectura avansată a ResNet50 și de augmentările de date care mimică diverse condiții de captare a imaginilor.

5 Rezultate

Această secțiune discută Rezultatele obținute după antrenarea modelelor descrise anterior sunt caracterizate nu numai de metricile de performanță, cum ar fi acuratețea, ci și prezentând exemple specifice de clasificare pentru a ilustra cum modelele răspund la diferite tipuri de imagini.

5.1 Acuratețe

Modelul-Arhitectura Personalizată CNN a arătat o acuratețe de aproximativ 30 din 100 pe setul de test, ceea ce indică un spațiu considerabil pentru îmbunătățiri. Factorii care pot contribui la această performanță suboptimală includ complexitatea variabilității în tipurile de leziuni ale pielii și posibilele limitări ale datelor de antrenament în ceea ce privește diversitatea și volumul.

Modelul-Transfer Learning cu ResNet50, utilizând arhitectura ResNet50 adaptată, a obținut o acuratețe impresionantă de 89 din 100 pe setul de antrenament. Această performanță superioară poate fi atribuită capacității modelului de a extrage caracteristici mai eficiente datorită adâncimii și sofisticării ResNet50, precum și tehnicilor de augmentare a datelor care au îmbunătățit capacitatea modelului de a generaliza.

5.2 Exemple de clasificare

Imaginea unei leziuni a fost corect identificată de modelul cu ResNet50 ca fiind actinic keratosis.




Figure 2: Actinic keratosis - ResNet50

Imaginea unei leziuni a fost corect identificată de modelul cu ResNet50 ca fiind melanoma. Acest rezultat a fost susținut și de modelul CNN, care semnificativ mai inaccuracy, detectează melanoma. Acest rezultat ar putea fi atribuit clarității caracteristicilor vizuale ale leziunii, care se potrivesc bine cu modelele învățate de rețeaua din setul de antrenament.




Figure 3: Melanoma - ResNet50,CNN

Într-un caz, modelul cu CNN, care are o acuratețe de 30 din 100, a clasificat greșit o leziune de melanoma ca fiind vascular leziune. Acest rezultat negativ poate fi datorat unei insuficiențe în caracteristicile extrase de model pentru această tipologie particulară de imagine, poate din cauza variației insuficiente în setul de date sau din cauza unui nivel de zgomot vizual care maschează trăsăturile critice ale malignității. De asemenea, acest lucru sugerează că modelul poate avea nevoie de un antrenament suplimentar sau de ajustări în arhitectura rețelei pentru a îmbunătăți recunoașterea modelelor complexe de leziuni.

Aceste exemple ilustrează importanța evaluării continue a modelelor în condiții variate și nevoia de a ajusta continuu procesul de antrenament și preprocesare pentru a optimiza performanța modelului. În plus, ele subliniază relevanța utilizării unor seturi de date diverse și reprezentative pentru antrenamentul modelelor de învățare automată în aplicații medicale.

6 Concluzie

Această cercetare a explorat eficacitatea și eficiența aplicării rețelelor neuronale convoluționale (CNN) pentru identificarea și clasificarea diferitelor tipuri de cancer de piele prin imagini dermatoscopice. Am dezvoltat și evaluat două modele diferite: un model CNN personalizat și un model bazat pe arhitectura ResNet50 pre-antrenată, folosind tehnici de transfer learning.

Modelul personalizat a demonstrat o acuratețe moderată pe setul de test, obținând o acuratețe de aproximativ 30 din 100. Acest rezultat indică necesitatea unor îmbunătățiri semnificative și sugerează că, deși modelul are potențial, este necesară ajustarea arhitecturii și o posibilă extindere a setului de date pentru a acoperi o gamă mai largă de variații ale leziunilor pielii. De asemenea, ar putea beneficia de o preprocesare mai avansată a imaginilor și de metode de augmentare mai sofisticate pentru a îmbunătăți generalizarea modelului.




Figure 4: Acuratețe - ResNet50,CNN

Pe de altă parte, modelul bazat pe ResNet50 a atins o acuratețe impresionantă de 89 din 100 pe setul de antrenament, demonstrând puterea arhitecturilor CNN avansate și a tehnicilor de transfer learning în extragerea trăsăturilor relevante din imagini complexe. Acest succes subliniază potențialul tehnologiilor de învățare profundă în aplicațiile de diagnos-

ticare medicală, oferind o bază solidă pentru implementări viitoare în medii clinice reale.

Analiza clasificărilor corecte și greșite ale ambelor modele oferă o perspectivă valoroasă asupra limitărilor actuale și asupra direcțiilor de îmbunătățire. Clasificările incorecte, în special, subliniază importanța diversității seturilor de date și a robusteții modelului la variațiile intrinseci ale datelor medicale.

În concluzie, studiul nostru evidențiază rolul crucial al datelor de calitate și al selecției arhitecturii adecvate în dezvoltarea sistemelor de inteligență artificială pentru medicină. Avansările în tehnologiile de procesare a imaginilor și în algoritmi de învățare automată deschid perspective promițătoare pentru îmbunătățirea diagnosticării și tratamentului cancerului de piele. Viitorul cercetării în acest domeniu ar trebui să se concentreze pe optimizarea modelelor pentru performanță în timp real, adaptabilitate la diverse condiții clinice și integrarea eficientă în fluxurile de lucru medicale.